



自适应滤波器

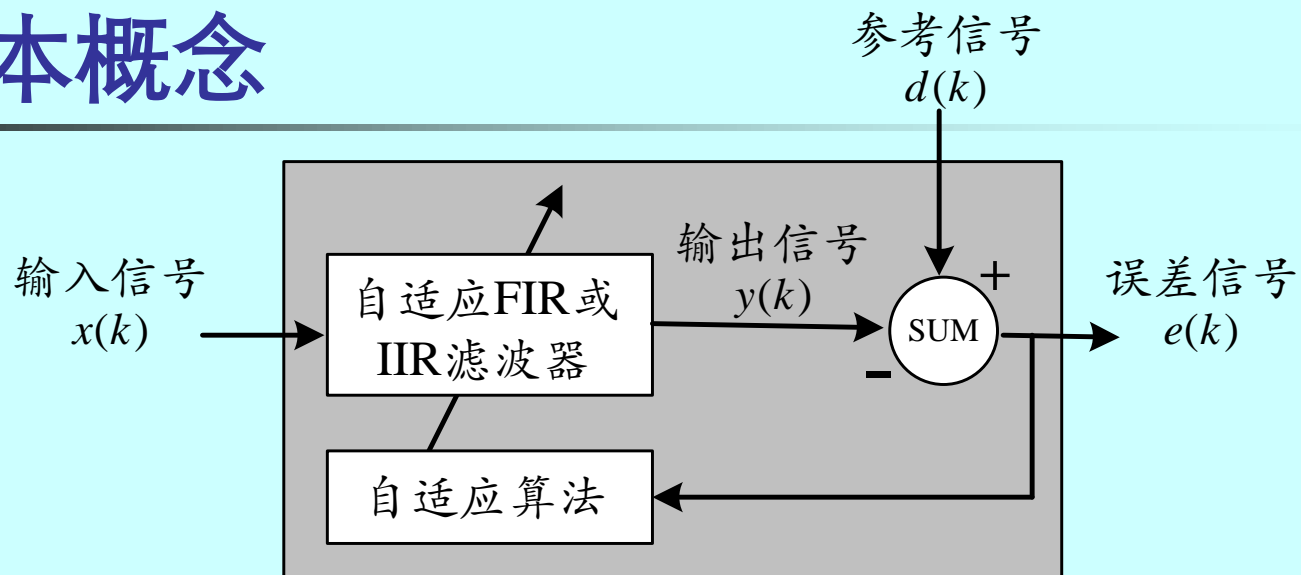
《工程信号处理及设备诊断》



提纲

- 基本概念
- 应用

基本概念



- 滤波器输入和输出

$$y(k) = x(k) * h(k)$$


- 定义滤波器的输出与特定参考信号的差值为误差信号

$$e(k) = d(n) - y(k)$$

- 自适应滤波器能够根据输入和参考信号的变化，自适应的调整滤波器系数，使得误差信号的均方值达到最小

$$E\{e^2(k)\} \Rightarrow \min$$

基本概念



■ 维纳-霍夫(Wiener-Hopf)方程

- 一般情况下，自适应滤波器均设计成FIR滤波器的形式，假定滤波器系数向量有 M 个系数

$$\mathbf{H} = [h(0), h(1), \dots, h(M-1)]^T$$

- 此时，系统的输入、输出关系为


$$y(k) = x(k) * h(k) = \sum_{m=0}^{M-1} h(m)x(k-m)$$

- 误差信号的均方值可写为

$$E\{e^2(k)\} = E\left\{\left[d(k) - \sum_{m=0}^{M-1} h(m)x(k-m)\right]^2\right\}$$

- 将上式对 $h(m)$ 求偏导，并且令偏导数等于零，则确定使均方误差最小时的 $h_{opt}(m)$

基本概念



■ 维纳-霍夫(Wiener-Hopf)方程

■ 求导

$$\frac{\partial E\{e^2(k)\}}{\partial h(j)} = 2E\left\{e(k) \frac{\partial e(k)}{\partial h(j)}\right\} = 0, \quad M-1 \geq j \geq 0$$

当均方误差最小时，
估计误差与滤波器的
输入正交

$$E\{e(k)x(k-j)\} = 0$$

■ 维纳-霍夫方程

$$e(k) = d(k) - \sum_{m=0}^{M-1} h(m)x(k-m)$$


$$r_{xd}(j) = \sum_{m=0}^{M-1} h_{opt}(m)r_{xx}(j-m) \quad M-1 \geq j \geq 0$$

$r_{xx}(j-m) = E\{x(n-j)x(n-m)\}$ autocorrelation sequence of $x(k)$

$r_{xd}(j) = E\{d(n)x(n-j)\}$ cross-correlation sequence of $x(k)$ and $d(k)$

基本概念


■ 维纳-霍夫(Wiener-Hopf)方程



$$r_{xd}(j) = \sum_{m=0}^{M-1} h_{opt}(m) r_{xx}(j-m) \quad j = 0, 1, 2, \dots, M-1$$

■ 矩阵形式维纳-霍夫方程

$$\begin{bmatrix} r_{xx}(0) & r_{xx}(1) & \cdots & r_{xx}(M-1) \\ r_{xx}(1) & r_{xx}(0) & \cdots & r_{xx}(M-2) \\ \vdots & \vdots & \cdots & \vdots \\ r_{xx}(M-1) & r_{xx}(M-2) & \cdots & r_{xx}(0) \end{bmatrix} \begin{bmatrix} h(0) \\ h(1) \\ \vdots \\ h(M-1) \end{bmatrix} = \begin{bmatrix} r_{xd}(0) \\ r_{xd}(1) \\ \vdots \\ r_{xd}(M-1) \end{bmatrix}$$



$$\mathbf{R}_{xx} \mathbf{H}_o = \mathbf{P}_{xd}$$



$$\mathbf{H}_o = \mathbf{R}_{xx}^{-1} \mathbf{P}_{xd}$$

复习

■ AR模型的正则方程

■ Yule-Walker方程

$$r_x(m) = \begin{cases} -\sum_{k=1}^p a_k r_x(m-k) & m \geq 1 \\ -\sum_{k=1}^p a_k r_x(m-k) + \sigma^2 & m = 0 \end{cases}$$

$$\begin{bmatrix} r_x(0) & r_x(1) & r_x(2) & \cdots & r_x(p) \\ r_x(1) & r_x(0) & r_x(1) & \cdots & r_x(p-1) \\ r_x(2) & r_x(1) & r_x(0) & \cdots & r_x(p-2) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ r_x(p) & r_x(p-1) & r_x(p-2) & \cdots & r_x(0) \end{bmatrix} \begin{bmatrix} 1 \\ a_1 \\ a_2 \\ \vdots \\ a_p \end{bmatrix} = \begin{bmatrix} \sigma^2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

一个 p 阶的AR模型共有 $p+1$ 个参数，即 $a_1, \dots, a_p, \sigma^2$ ，只要知道 $x(n)$ 的前 $p+1$ 个自相关函数值，就可以通过求解线性方程组解出AR模型参数的值

基本概念

■ 维纳-霍夫(Wiener-Hopf)方程

$$\mathbf{R}_{xx} \mathbf{H}_o = \mathbf{P}_{xd}$$

$$\begin{bmatrix} r_{xx}(0) & r_{xx}(1) & \cdots & r_{xx}(M-1) \\ r_{xx}(1) & r_{xx}(0) & \cdots & r_{xx}(M-2) \\ \vdots & \vdots & \cdots & \vdots \\ r_{xx}(M-1) & r_{xx}(M-2) & \cdots & r_{xx}(0) \end{bmatrix} \begin{bmatrix} h(0) \\ h(1) \\ \vdots \\ h(M-1) \end{bmatrix} = \begin{bmatrix} r_{xd}(0) \\ r_{xd}(1) \\ \vdots \\ r_{xd}(M-1) \end{bmatrix}$$

■ 定义输入向量为:

$$\mathbf{x}(k) = [x(k), x(k-1), \dots, x(k-M+1)]^T$$

■ 输入向量 $M \times M$ 的相关矩阵可写为

$$\mathbf{R}_{xx} = E\{\mathbf{x}(k)\mathbf{x}^T(k)\}$$

■ 输入向量与期望响应的 $M \times 1$ 互相关向量可写为

$$\mathbf{P}_{xd} = E\{\mathbf{x}(k)d(k)\}$$

基本概念

■ 自适应滤波器的最速下降算法

■ 滤波器系数的直接算法

$$\mathbf{H}_o = \mathbf{R}_{xx}^{-1} \mathbf{P}_{xd}$$

- 虽然通过上式可以实现滤波器最优系数的求解，但实际中并不利用相关矩阵的求逆来实现。这是因为对于庞大的矩阵，求逆将会带来巨大的计算量。
- 滤波器的最优求解一般都通过迭代的方式
- 定义代价函数 $J(\mathbf{H})$ ， $J(\mathbf{H})$ 是滤波器系数向量 \mathbf{H} 的函数。通过多次迭代使滤波器的系数向量逐渐趋近于最优解 \mathbf{H}_o ，并且对于所有的 \mathbf{H} 满足

$$J(\mathbf{H}_o) \leq J(\mathbf{H})$$

基本概念

■ 自适应滤波器的最速下降算法

- 迭代过程的一般描述为：从某一初始猜想 $\mathbf{H}(0)$ 出发，通过迭代依次产生一系列的滤波器系数向量 $\mathbf{H}(1), \mathbf{H}(2), \dots$ 使得代价函数在算法的每次迭代都是下降的，即

$$J(\mathbf{H}(k+1)) < J(\mathbf{H}(k))$$

- 常用迭代方法是最速下降法，即沿着代价函数 $J(\mathbf{H})$ 的负梯度方向，连续地调整滤波器系数向量。迭代过程可以表示为：

$$\mathbf{H}(k+1) = \mathbf{H}(k) - \frac{1}{2} \mu \nabla J(\mathbf{H}(k))$$


- 其中 μ 是步长参数， $1/2$ 因子的引入是为了数学上的处理方便

基本概念

■ 自适应滤波器的最速下降算法

■ 代价函数 $J(\mathbf{H})$ 用误差信号的均方值表示

$$J(\mathbf{H}(k)) = E\{e(k)^2\}$$



$$\mathbf{x}(k) = [x(k), x(k-1), \dots, x(k-M+1)]^T$$

$$\mathbf{H}(k) = [h(0), h(1), \dots, h(M-1)]^T$$

$$\begin{aligned} e(k) &= d(k) - \sum_{m=0}^{M-1} h(m)x(k-m) \\ &= d(k) - \mathbf{x}^T(k)\mathbf{H}(k) \end{aligned}$$

$$J(\mathbf{H}(k)) = E\{d(k)^2\} - \mathbf{H}^T(k)\mathbf{P}_{xd} - \mathbf{P}_{xd}^T\mathbf{H}(k) + \mathbf{H}^T(k)\mathbf{R}_{xx}\mathbf{H}(k)$$

基本概念

■ 自适应滤波器的最速下降算法

- 代价函数 $J(\mathbf{H})$ 对 \mathbf{H} 求导, 可得

$$J(\mathbf{H}(k)) = E\{d(k)^2\} - \mathbf{H}^T(k) \mathbf{P}_{xd} - \mathbf{P}_{xd}^T \mathbf{H}(k) + \mathbf{H}^T(k) \mathbf{R}_{xx} \mathbf{H}(k)$$




$$\nabla J(\mathbf{H}(k)) = -2\mathbf{P}_{xd} + 2\mathbf{R}_{xx} \mathbf{H}(k)$$

- 最速下降算法迭代过程

$$\mathbf{H}(k+1) = \mathbf{H}(k) - \frac{1}{2} \mu \nabla J(\mathbf{H}(k)) = \mathbf{H}(k) + \mu [\mathbf{P}_{xd} - \mathbf{R}_{xx} \mathbf{H}(k)]$$

$$e(k) = d(k) - \mathbf{x}^T(k) \mathbf{H}(k)$$



$$\mathbf{R}_{xx} = E\{\mathbf{x}(k) \mathbf{x}^T(k)\}$$

$$\mathbf{P}_{xd} = E\{\mathbf{x}(k) d(k)\}$$

$$\mathbf{H}(k+1) = \mathbf{H}(k) + \mu E\{\mathbf{x}(k) e(k)\}$$

- 当输入信号和误差信号正交时, 系数向量达到最优解 \mathbf{H}_0 .


基本概念

■ 最小均方(LMS, least-mean-square)自适应滤波器算法

- 最速下降算法需要计算输入向量的自相关矩阵 \mathbf{R}_{xx} 及其与期望响应的互相关向量 \mathbf{P}_{xd}
- 最小均方自适应迭代算法是利用 \mathbf{R}_{xx} 和 \mathbf{P}_{xd} 的瞬时估计值实现迭代

$$\hat{\mathbf{P}}_{xd} = \mathbf{x}(k)d(k)$$

$$\hat{\mathbf{R}}_{xx} = \mathbf{x}(k)\mathbf{x}^T(k)$$



$$\mathbf{R}_{xx} = E\{\mathbf{x}(k)\mathbf{x}^T(k)\}$$

$$\mathbf{P}_{xd} = E\{\mathbf{x}(k)d(k)\}$$

$$\mathbf{x}(k) = [x(k), x(k-1), \dots, x(k-M+1)]^T$$

基本概念

■ LMS自适应滤波器算法

- LMS算法是Widrow和Hoff在1960年的一次学术会议上提出的，该算法的显著特点就是简单而且有效，常作为其他线性自适应滤波算法的参照标准

Google 学术搜索 [学术高级搜索](#)

☒ 搜索所有网页 ☐ 中文网页 ☐ 简体中文网页

学术搜索 时间不限 约有 101

小提示: [只搜索中文\(简体\)结果](#), 可在 [学术搜索设置](#) 指定搜索语言

[PDF] Adaptive switching circuits
B Widrow, ME Hoff... - 1960 - isl-www.stanford.edu
ADAPTIVE SWITCHING CIRCUITS Bernard Widrow and Marciali E. Hoff A. Introduction
The-modern science of **switching** theory began with work by Shannon¹ in 1938. The field has de- veloped rapidly since then, and at present a wealth of literature exists² concerning ...
[被引用次数: 2221](#) - [相关文章](#) - [所有 10 个版本](#)

基本概念

■ LMS自适应滤波器算法

■ LMS算法迭代过程

$$\hat{\mathbf{H}}(k+1) = \hat{\mathbf{H}}(k) + \mu[\mathbf{x}(k)e(k)] \quad \leftarrow \quad \begin{aligned} \hat{\mathbf{R}}_{xx} &= \mathbf{x}(k)\mathbf{x}^T(k) & \hat{\mathbf{P}}_{xd} &= \mathbf{x}(k)d(k) \\ \hat{\mathbf{H}}(k+1) &= \hat{\mathbf{H}}(k) + \mu[\hat{\mathbf{P}}_{xd} - \hat{\mathbf{R}}_{xx}\mathbf{H}(k)] \end{aligned}$$

- 由于梯度噪声的存在，在迭代结束时，代价函数将不再收敛于 $J(\mathbf{H}_0)$ ，其稳定解与维纳解 $J(\mathbf{H}_0)$ 相差的程度称之为失调。在设计自适应滤波器时，失调是可以控制的。采用较小的步长参数 μ ，可以很大程度上削弱使梯度噪声对滤波器系数的影响。
- 但是步长参数 μ 取得过小会是迭代计算变慢，对外界的变化不灵敏

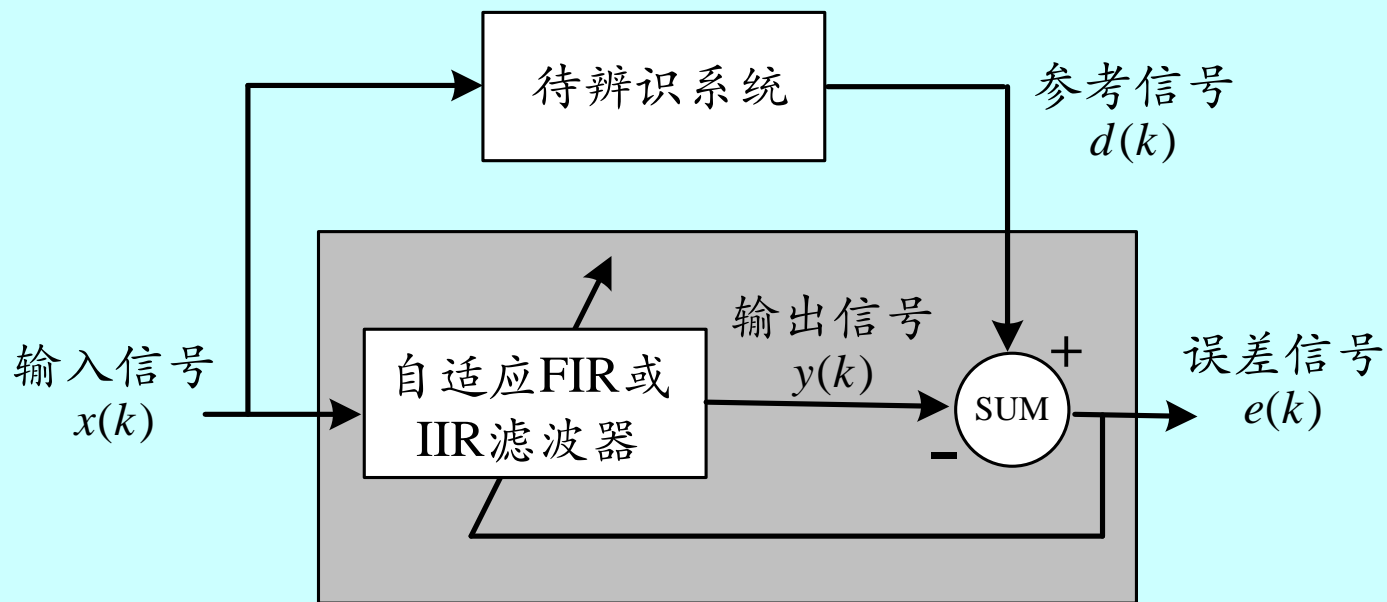


自适应滤波器的应用

- 时变在线系统辨识
- 自适应噪声消除
 - 声音信号的谐波干扰消除
 - 正弦信号里的随机噪声消除
 - 管道噪声自适应消除
 - 胎儿心电监护

自适应滤波器的应用

■ 系统辨识




adaptive_filters_01_system_ID.m

自适应滤波器的应用

■ 自适应噪声消除

■ 声音信号的谐波干扰消除

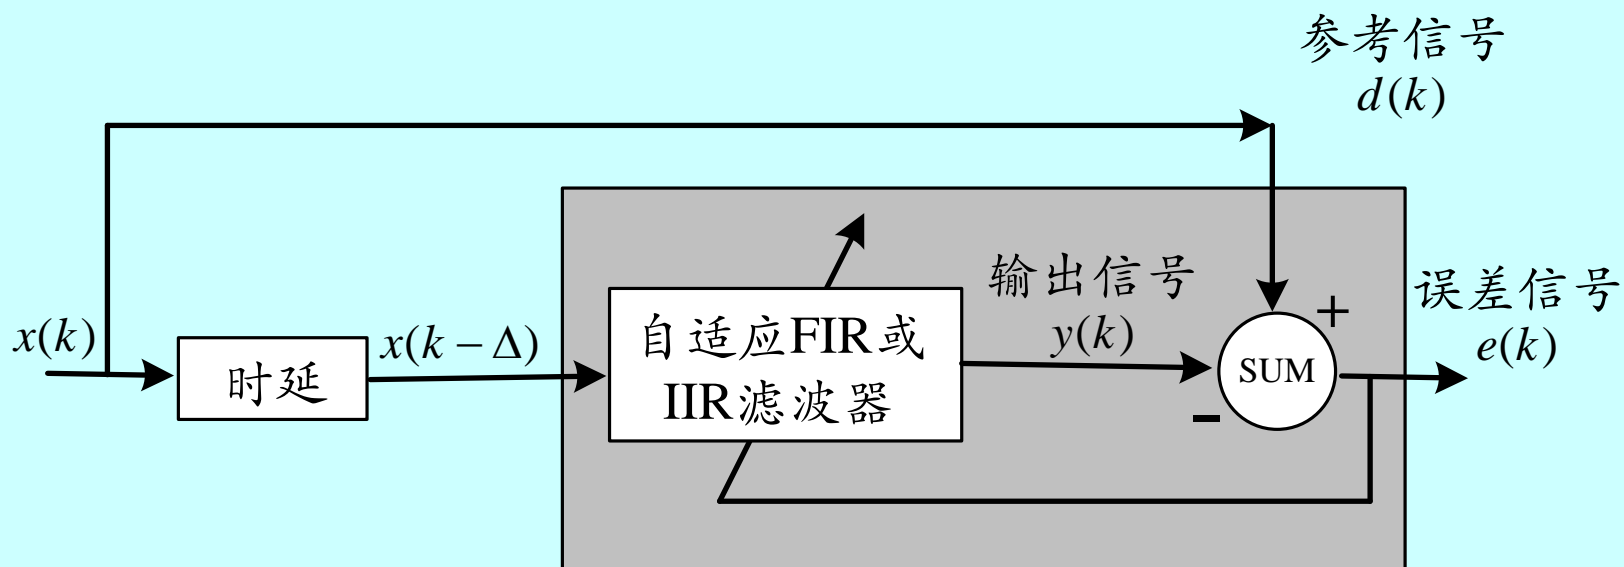


adaptive_filters_02_adapt_noise_cancellation.m

自适应滤波器的应用

■ 自适应噪声消除

■ 正弦信号里的随机噪声消除

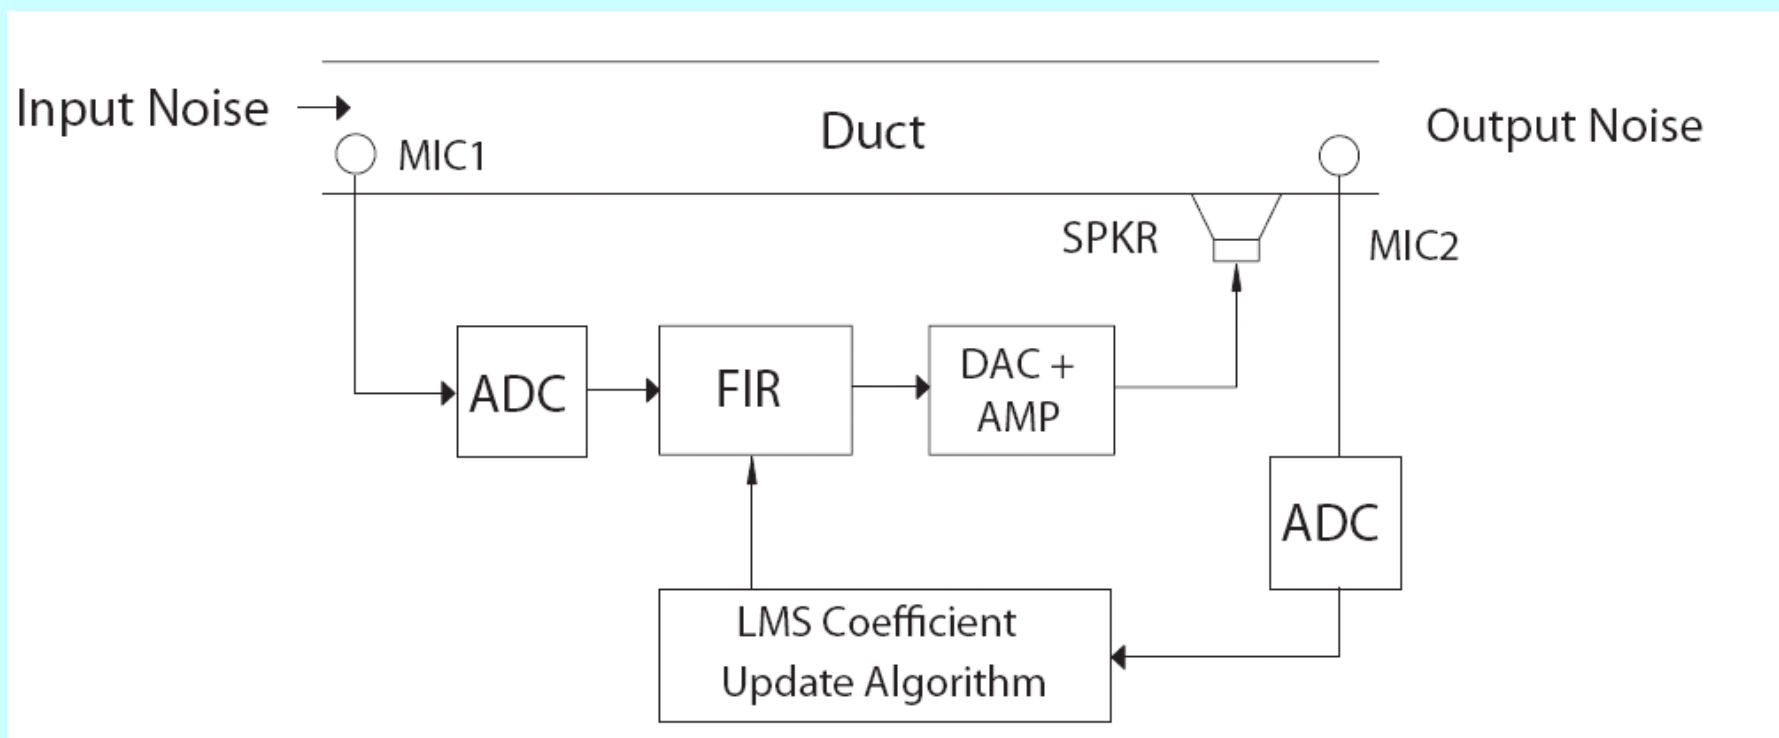


adaptive_filters_03_adapt_noise_cancellation.m

自适应滤波器的应用

自适应噪声消除

■ 管道噪声自适应消除

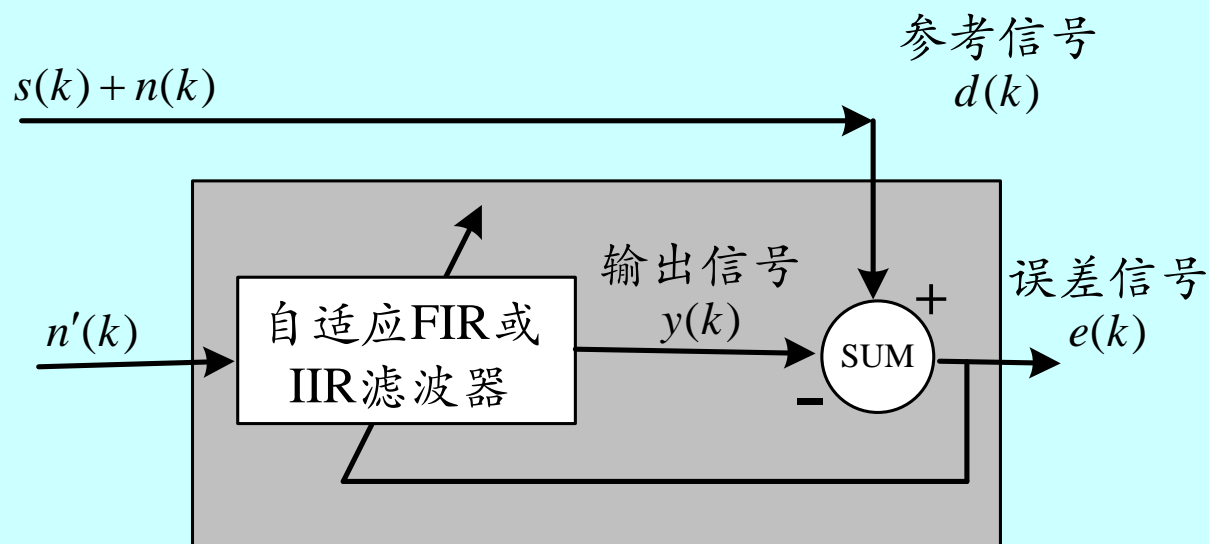


adaptive_filters_04_adapt_noise_cancellation.m

自适应滤波器的应用

■ 自适应噪声消除

■ 胎儿心电监护



adaptive_filters_05_adapt_noise_cancellation.m



The End

谢谢!

请批评指正

